Machine Learning aplicado a la predicción de cancelaciones hoteleras

PROYECTO PRÁCTICO FINAL

Isabel Alonso Casas

Bibiana Dorado Mateos

Machine Learning I: Fundamentos y Aprendizaje Supervisado

Universidad Pontificia Comillas, ICAI

Profesor: Miguel Ángel Sanz Bobi

21 de abril de 2026

COMILLAS UNIVERSIDAD PONTIFICIA ICAI

ÍNDICE

Introducción y motivación 3

Objetivo y necesidades 4

Desarrollo del trabajo 6

1. Organización del equipo de trabajo 6

2. Flujo general de trabajo 6

3. EDA 8

4. Limpieza y preparación de los datos 18

5. Algoritmos empleados 18

a. Naive Bayes 18

b. Regresion logistica 19

c. KNN 21

d. Árbol de decisión CART 21

e. Ensemble 24

i. Bagging: Random Forest (CART) 24

ii. Boosting: Gradient Boosting (CART) 25

iii. Voting Soft (Votes) 25

iv. Voting Hard (Probabilities) 26

f. Redes Neuronales 27

Comparación los modelos y elección del mejor modelo 28

Explicabilidad e interpretabilidad del modelo Random Forest seleccionado como mejor modelo 30

Resultados e interpretación 35

Comparación con la propuesta inicial 36

Conclusiones y recomendaciones 37

Introducción y motivación

El objetivo del presente proyecto es desarrollar un modelo predictivo basado en técnicas de Machine Learning que permita anticipar la cancelación de reservas hoteleras a partir de información disponible en una base de datos del sector.

En la actualidad, la industria hotelera opera en un entorno competitivo y digitalizado, donde la gestión eficiente de la demanda es clave para poder maximizar los ingresos. En este contexto, la cancelación de reservas constituye un problema relevante para la gestión de ingresos y la planificación operativa. Las cancelaciones generan incertidumbre en la ocupación futura del hotel y pueden provocar pérdidas económicas derivadas de:

- Habitaciones que quedan finalmente vacías.
- Sobrecostes operativos.
- Decisiones ineficientes de precios.

Ante esta problemática, el desarrollo de herramientas de analítica predictiva permite a los establecimientos hoteleros identificar patrones de comportamiento y anticipar la probabilidad de cancelación, mejorando así la toma de decisiones estratégicas.

Desde un punto de vista metodológico, el problema abordado se enmarca en una clasificación binaria, donde el objetivo principal es determinar si una reserva será cancelada o no a partir de un conjunto de variables explicativas.

El proyecto se orienta de forma general a aplicar técnicas aprendidas de Machine Learning para este análisis, evaluando de esta manera su utilidad en un problema real del ámbito empresarial. Usaremos estas técnicas por su capacidad para detectar patrones complejos a través del uso de Big Data.

A través de los resultados obtenidos, se podrán crear estrategias de retención o ajustes de pricing en empresas que se enfrenten a este problema.

Objetivo y necesidades

El objetivo general del proyecto es el desarrollo de un modelo de Machine Learning capaz de predecir la cancelación de reservas hoteleras a partir de datos históricos, con el fin de mejorar la toma de decisiones en el ámbito de la gestión hotelera.

Para poder desarrollar el proyecto tendremos que realizar los siguientes objetivos más específicos:

- Analizar y comprender la base de datos seleccionada y sus variables a través de un Análisis Exploratorio de Datos (EDA) inicial.
- Identificar los problemas posibles en los datos, como outliers o valores perdidos a la vez que estudiar si podría ser un problema el desbalance de clases.
- Tras el procesado de datos, implementar y entrenar distintos métodos de clasificación para predecir si una reserva será cancelada o no.
- Identificar las variables más relevantes que influyen en la cancelación.
- Comparar el rendimiento de distintos algoritmos para determinar cuál ofrece mejores resultados predictivos.
- Interpretar los resultados obtenidos y sacar conclusiones relevantes para el sector.

Este enfoque permitirá demostrar la utilidad del Machine Learning aplicado a problemas reales del ámbito empresarial, concretamente en la optimización de la gestión de reservas en el sector hotelero.

En cuanto a lo que necesidades se refiere, podemos diferenciar los siguientes subapartados:

a) **Necesidades de datos:** Para poder llevar a cabo el análisis necesitaremos de una base de datos representativa del comportamiento real de los clientes. Las variables deberán ser relevantes y numerosas. Debemos contar con suficiente volúmen de datos para entrenar los modelos. Estos datos tienen que ser de calidad, sin gran cantidad de valores inconsistentes o vacíos.

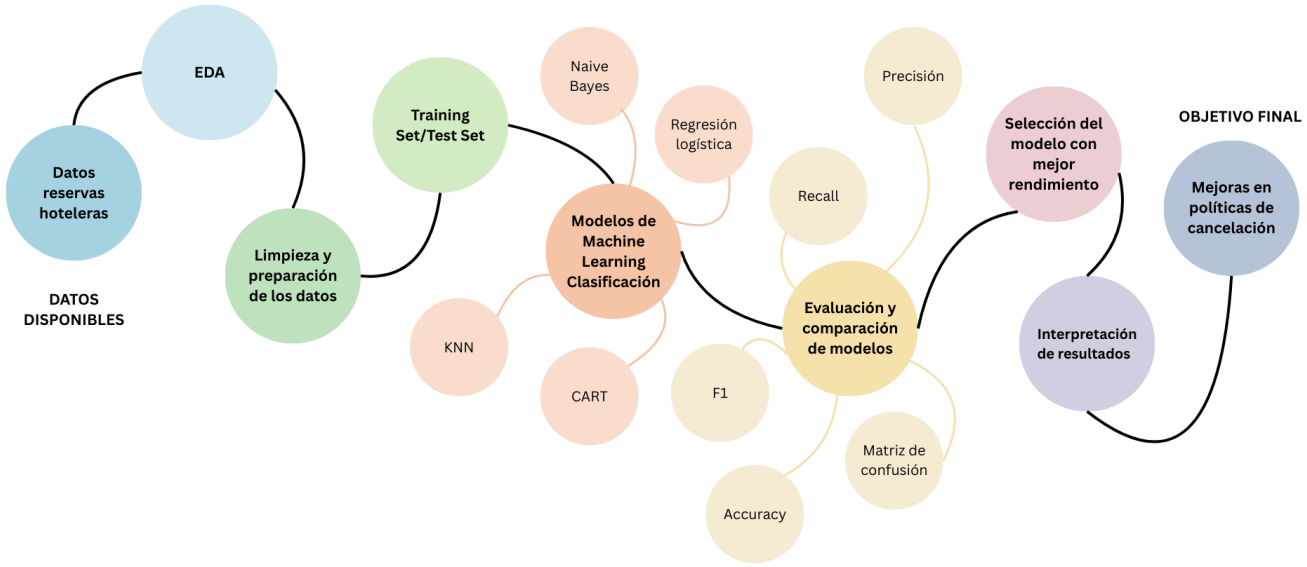
b) **Necesidades técnicas:** Se necesitarán diferentes herramientas de análisis de datos, en conjunto con librerías de Machine Learning para agilizar la creación y evaluación de modelos. También, un entorno de desarrollo adecuado.

c) **Necesidades metodológicas:** Una definición clara del objetivo del problema. Una selección de métricas de evaluación adecuadas. Llevar a cabo estrategias para evitar el overfitting. Validación exhaustiva de los modelos.

d) **Necesidades de negocio:** Generación de información relevante y capacidad para integrar el modelo seleccionado en sistemas de gestión hotelera. Interpretabilidad del modelo para facilitar su uso a las empresas del sector.

El correcto cumplimiento de estas necesidades nos permitirá garantizar la validez del análisis y de nuestro trabajo y la aplicabilidad de los resultados obtenidos.

Flujo metodológico del proyecto de Machine Learning para la predicción de cancelaciones hoteleras[1]



[1] **Figura 1**. Flujo metodológico del proyecto de Machine Learning para la predicción de cancelaciones hoteleras, se incluye lo visto hasta ahora en la asignatura, si se estudiase a posteriori alguna metodología más que pudiera ser utilizada en el trabajo, se añadiría a este.

Desarrollo del trabajo

1. Organización del equipo de trabajo

Ambas personas han contribuido de manera completamente equitativa en la elaboración y entrega del trabajo. El desarrollo del mismo se ha llevado a cabo de forma presencial, trabajando conjuntamente en todo momento para alcanzar los objetivos propuestos. La implicación, dedicación y participación han sido iguales por ambas partes en todas las fases del proyecto.

2. Flujo general de trabajo

El desarrollo del proyecto se ha llevado a cabo siguiendo un flujo de trabajo estructurado, que abarca desde el análisis exploratorio inicial hasta la selección del modelo final. A continuación, se describen las principales etapas del proceso:

1.1. Análisis Exploratorio de Datos (EDA)

En primer lugar, se realizó un análisis exploratorio con el objetivo de comprender la naturaleza del dataset y detectar posibles problemas en los datos. Este análisis incluyó:

- Evaluación de la estructura del conjunto de datos (número de observaciones, variables y tipos de datos).
- Identificación y tratamiento de valores nulos e inconsistencias.
- Cálculo de estadísticos descriptivos para variables numéricas.
- Análisis de la distribución de las variables categóricas.
- Estudio de la variable objetivo (**cancelación de reservas**), incluyendo su distribución.
- Exploración de relaciones entre variables mediante matrices de correlación.

1.2. Preparación y división del conjunto de datos

Posteriormente, basándonos en el análisis previo, se pasa a limpiar y codificar el dataset. A continuación, se divide en conjuntos de entrenamiento (train) y prueba (test), con el fin de evaluar la capacidad de generalización de los modelos.

1.3. Entrenamiento de modelos

Se implementaron y entrenaron distintos algoritmos de clasificación para abordar el problema:

- Naive Bayes
- Regresión Logística
- K-Nearest Neighbors (KNN)
- Árboles de decisión (CART)
- Métodos ensemble:
    - Random Forest
    - Gradient Boosting
    - Voting (Hard y Soft)
- Redes neuronales (optimizadas mediante el algoritmo “Adam”)

1.4. Evaluación de modelos

Cada uno de los modelos fue evaluado utilizando diversas métricas para obtener una visión completa de su rendimiento:

- Matriz de confusión
- Métricas principales:
    - Accuracy
    - Precision
    - Recall
    - F1-score
    - Specificity
- Análisis de la curva ROC y cálculo del área bajo la curva (AUC)

1.5. Comparación y selección del modelo

Finalmente, se elaboró una tabla comparativa con los resultados obtenidos por cada modelo. A partir de este análisis, se seleccionó el modelo con mejor desempeño global, teniendo en cuenta tanto las métricas cuantitativas como la capacidad de generalización.

3. EDA

3.1. Análisis de la estructura del dataset

En un primer lugar se pretende identificar las variables del dataset. A continuación se muestra una lista con todas, con su correspondiente explicación:

- hotel: Tipo de hotel (resort o city)
- is_canceled: Si la reserva fue cancelada (1 sí, 0 no)
- lead_time: Días entre reserva y llegada
- arrival_date_year: Año de llegada
- arrival_date_month: Mes de llegada
- arrival_date_week_number: Semana del año
- arrival_date_day_of_month: Día del mes
- stays_in_weekend_nights: Noches en fin de semana
- stays_in_week_nights: Noches entre semana
- adults: Número de adultos
- children: Número de niños
- babies: Número de bebés
- meal: Tipo de pensión
  - Undefined/SC – no meal package
  - BB – Bed & Breakfast
  - HB – Half board (breakfast and one other meal – usually dinner)
  - FB – Full board (breakfast, lunch and dinner)
- country: País del cliente (Representado en ISO)
- market_segment: Segmento de mercado
  - "TA" - "Travel Agents"
  - "TO" - "Tour Operators"
- distribution_channel: Canal de reserva
  - "TA" - "Travel Agents"
  - "TO" - "Tour Operators"
- is_repeated_guest: Cliente repetido (1 sí, 0 no)
- previous_cancellations: Cancelaciones previas
- previous_bookings_not_canceled: Reservas previas no canceladas
- reserved_room_type: Tipo de habitación reservada (por protección se utiliza ID)
- assigned_room_type: Tipo de habitación asignada (por protección se utiliza ID)
- booking_changes: Cambios en la reserva
- deposit_type: Tipo de depósito
  - No Deposit – no deposit was made
  - Non Refund – a deposit was made in the value of the total stay cost
  - Refundable – a deposit was made with a value under the total cost of stay.
- agent: ID del agente que hizo la reserva
- company: ID de la empresa/entidad que hizo la reserva
- days_in_waiting_list: Días en lista de espera
- customer_type: Tipo de cliente
  - Contract - when the booking has an allotment or other type of contract associated to it
  - Group – when the booking is associated to a group
  - Transient – when the booking is not part of a group or contract, and is not associated to other transient booking
  - Transient-party – when the booking is transient, but is associated to at least other transient booking
- adr: Precio medio diario de la reserva. Se calcula dividiendo el ingreso total generado por la reserva entre el número total de noches de estancia. Indica cuánto paga, de media, un cliente por noche.

```
- required_car_parking_spaces: Plazas de parking requeridas
- total_of_special_requests: Número de peticiones especiales
- reservation_status: Estado último de la reserva
 - Canceled – booking was canceled by the customer
 - Check-Out – customer has checked in but already departed
 - No-Show – customer did not check-in and did inform the hotel of the reason why
- reservation_status_date: Fecha del estado último
```

El dataset analizado contiene 119.390 observaciones y 32 variables, lo que indica un volumen de datos suficientemente grande para aplicar técnicas de Machine Learning con buena capacidad de generalización.

En cuanto a los tipos de variables:

- Se observan variables numéricas (int64 y float64), principalmente relacionadas con características de la reserva (lead_time, número de noches, ADR, etc.).
- También existen múltiples variables categóricas (object) como el tipo de hotel, país, segmento de mercado o tipo de cliente, que serán relevantes en el análisis pero requerirán transformación posterior para su uso en modelos.

Por último, la variable objetivo "**is_canceled**" está correctamente definida como variable binaria (0 = no cancelada, 1 = cancelada), lo que confirma que el problema a abordar es de clasificación supervisada.

3.2. Análisis de valores nulos e inconsistencias

No solo bastará con estudiar las columnas con valores nulos sino que también revisamos posibles inconsistencias. En cuanto a valores nulos, obtenemos los siguientes resultados:

```
company     112593
agent        16340
country        488
children         4
```

Las inconsistencias que vamos a estudiar son:

- Reservas cuyo número de huéspedes, tanto de adultos como de niños o bebés sea nulo.
- Reservas con únicamente niños o bebés. Estas pueden o ser un fallo o ser habitaciones a nombre de niños al estar sus padres en otra habitación, en cuyo caso, la decisión de ser o

no cancelada la reserva recaerá exclusivamente en los padres, por tanto estas filas no nos dan tampoco información.

- Estancias cuyo número de noches sea nulo.
- Estancias cuyo adr (precio medio de cliente por noche) sea negativo.

Obtenemos los resultados:

```
Reservas sin huéspedes: 180 (0.1508%)
Reservas con niños/bebés pero sin adultos: 223 (0.1868%)
Reservas sin noches: 715 (0.5989%)
Reservas con ADR negativo: 1 (0.0008%)
```

Tras un estudio para ver cuántas de las filas habría que eliminar en total, teniendo en cuenta que los valores nulos pueden pertenecer a las mismas filas, obtenemos un número total de líneas a eliminar de 1526, lo que equivale a un 1.2782% del total del dataset.

Dado que este porcentaje es muy bajo, la eliminación de estas observaciones no afectará significativamente a la representatividad de los datos, permitiendo trabajar con un dataset más limpio y consistente para el modelado.

3.3. Estadísticos descriptivos en variables numéricas

En este proyecto se aplicará normalización a las variables numéricas, manteniendo sin transformar las variables binarias.

La normalización consiste en escalar las variables para que tengan una distribución comparable (por ejemplo, media 0 y desviación típica 1 en el caso de la estandarización). Este proceso es necesario por los siguientes motivos:

- Las variables del dataset presentan escalas muy diferentes:
  - “lead_time” puede alcanzar valores de hasta 737 días.
  - “adr” presenta valores muy elevados (hasta 5400).
  - “days_in_waiting_list” llega hasta 391.
  - Otras variables como “babies” o “children” tienen valores muy pequeños.

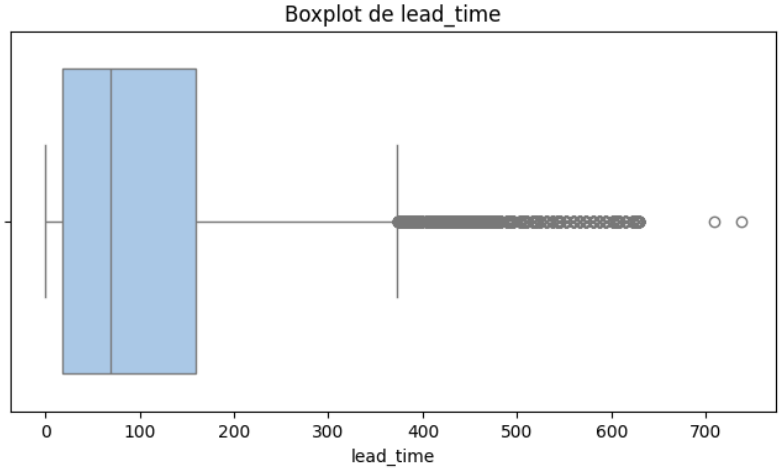
- Los algoritmos de Machine Learning basados en distancias (como KNN) o en optimización (como Regresión Logística) son sensibles a la escala de las variables. Si no se normalizan, las variables con valores más altos dominarán el modelo.
- La normalización mejora la convergencia de los modelos, la estabilidad numérica y la interpretabilidad de los coeficientes.

Por otro lado, no se normalizan las variables binarias (como "is_canceled" o "is_repeated_guest") porque:

- Ya están en una escala homogénea (0 y 1).
- No aportaría información adicional el transformarlas.

A partir del análisis descriptivo, se identifican variables con alta dispersión o valores extremos que pueden influir negativamente en el modelo. El uso de boxplots permitirá identificar visualmente estos valores y tomar decisiones fundamentadas en la fase de preprocesamiento. Se analiza en detalle las siguientes variables:

- Lead_time:
    - Presenta un rango muy amplio (0 a 737 días).
    - Pero tiene utilidad para saber si se hace la reserva con mucha antelacion si afecta a nuestra variable objetivo

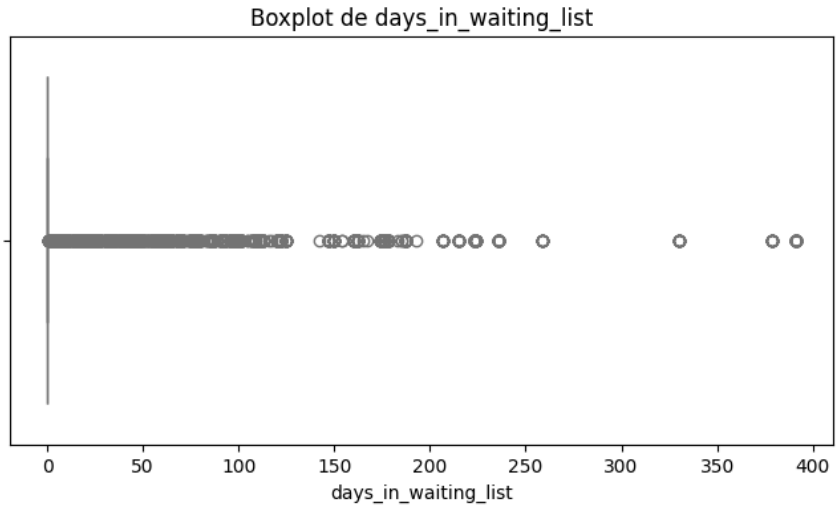


[2]

- Days_in_waiting_list:

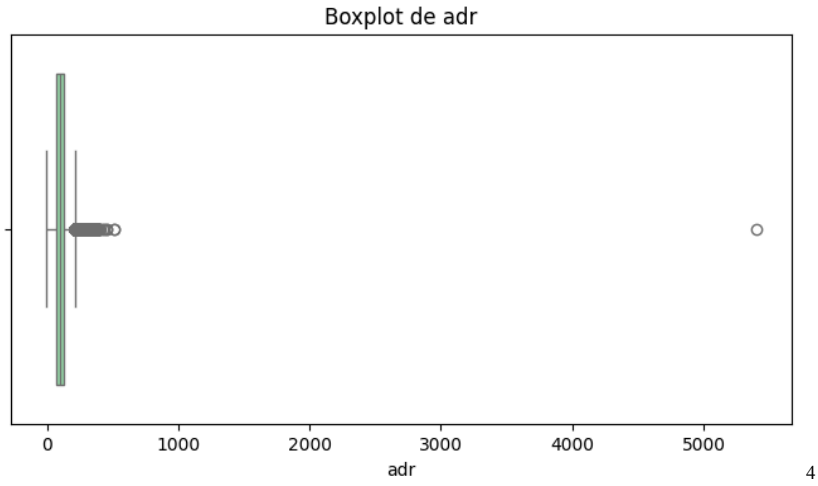
[2] Boxplot de la variable lead_time

- Valores muy dispersos, con máximos elevados (hasta 391 días), aunque posibles en el mundo de la hostelería.



[3]

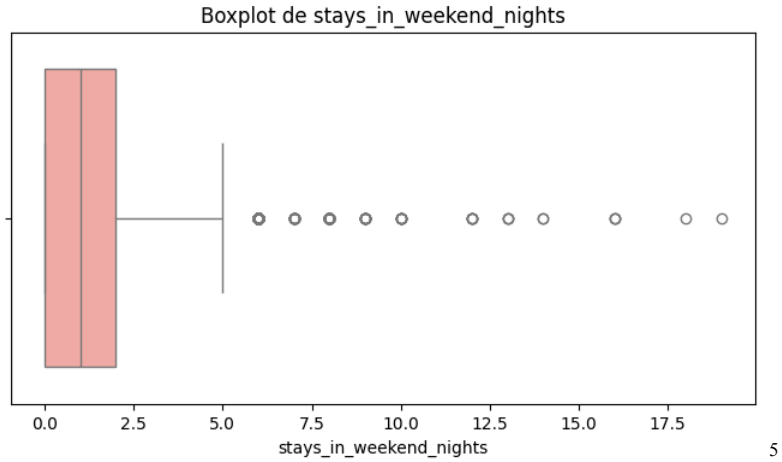
- Adr:
  - Se observan valores extremadamente altos (hasta 5400).
  - También se detectan valores negativos, lo cual es inconsistente.



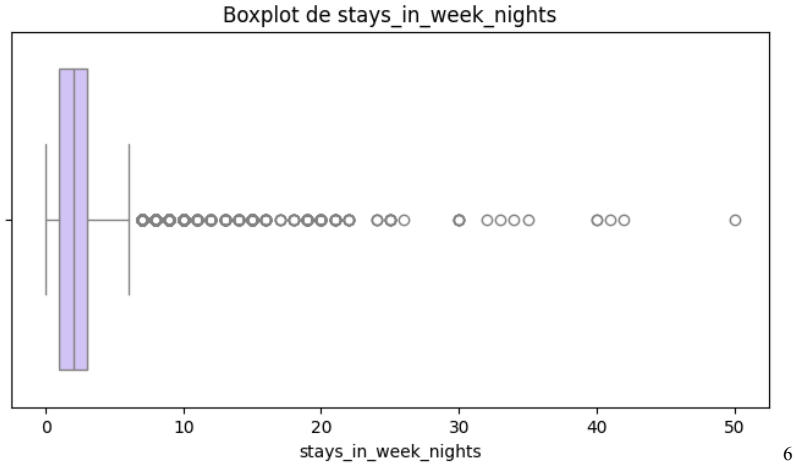
[4]

- Stays_in_week_nights y stays_in_weekend_nights:
  - Máximos elevados (hasta 50 noches), lo que puede indicar outliers, aunque también son posibles las estancias largas en hoteles.

[3] Boxplot de days_in_waiting_list
[4] Boxplot de adr



[5]



[6]

Tras el análisis mediante boxplots, se observa la presencia de valores extremos en varias variables. Sin embargo, no todos los outliers deben ser eliminados.

En la mayoría de las variables (como “lead_time”, “days_in_waiting_list”, “stays_in_weekend_nights” o ”stays_in_week_nights”), los valores extremos representan comportamientos reales del negocio (reservas con mucha antelación, estancias largas, etc.), por lo que se decide no eliminarlos para no perder información relevante.

No obstante, en la variable “adr” se detecta un valor extremadamente alto (superior a 5000), claramente alejado del comportamiento habitual de los datos.

[5] Boxplot de stays_in_weekend_nights
[6] Boxplot de stays_in_week_nights

Por ello, se decide:

- Eliminar valores negativos de “adr” (inconsistentes)
- Eliminar valores extremadamente altos (`adr > 5000`)

Este enfoque permite mantener la información relevante del dataset, evitando al mismo tiempo que valores anómalos distorsionen el modelo.

2.3. Estudio de variables categóricas

Durante el análisis de las variables categóricas se observa que muchas de ellas presentan un elevado número de categorías, lo que puede generar un aumento significativo en la dimensionalidad del dataset tras aplicar técnicas como One-Hot Encoding. Esto puede provocar: Mayor complejidad en el modelo, riesgo de sobreajuste, aumento del ruido en los datos.

Por ello, se han tomado las siguientes decisiones:

1. Se considera relevante crear una nueva variable:
    - room_changed: indica si la habitación reservada es distinta de la asignada.

Esta variable se define como:

- 1 → si “reserved_room_type” ≠ “assigned_room_type”
- 0 → si son iguales

La creación de esta variable permite capturar información relevante sobre posibles cambios en la reserva, que pueden estar relacionados con la satisfacción del cliente y la probabilidad de cancelación. Además, permite reducir la complejidad del modelo al sustituir dos variables categóricas por una variable binaria.

2. Se considera relevante agrupar la variable “country”:
    - Presenta un elevado número de categorías.
    - Se agruparán los países menos frecuentes en una categoría "Other" para reducir dimensionalidad (ITA, IRL ,BEL , BRA, NLD...)-

3. Se considera relevante eliminar las siguientes variables porque pueden causar overfitting en el modelo:
    - reservation_status
    - reservation_status_date

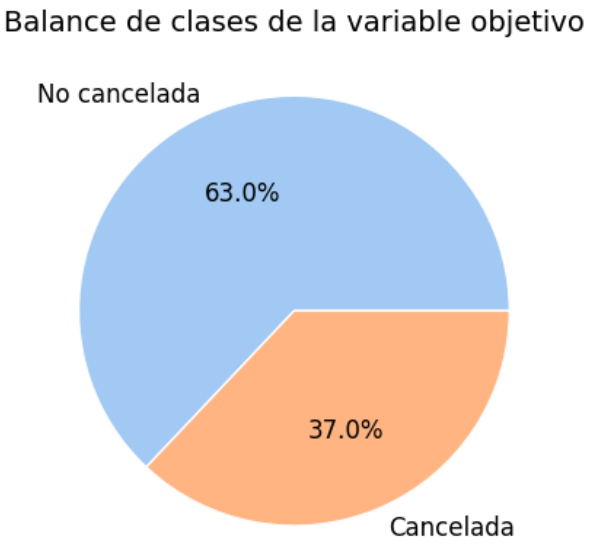
2.4. Análisis de la variable objetivo "is_canceled"

La variable objetivo del modelo es "is_canceled", que indica si una reserva ha sido cancelada o no, siguiendo los valores:

- 0 → Reserva no cancelada
- 1 → Reserva cancelada

Se observa la siguiente distribución:

- Reservas no canceladas (0): 75.166 → 62.96%
- Reservas canceladas (1): 44.224 → 37.04%



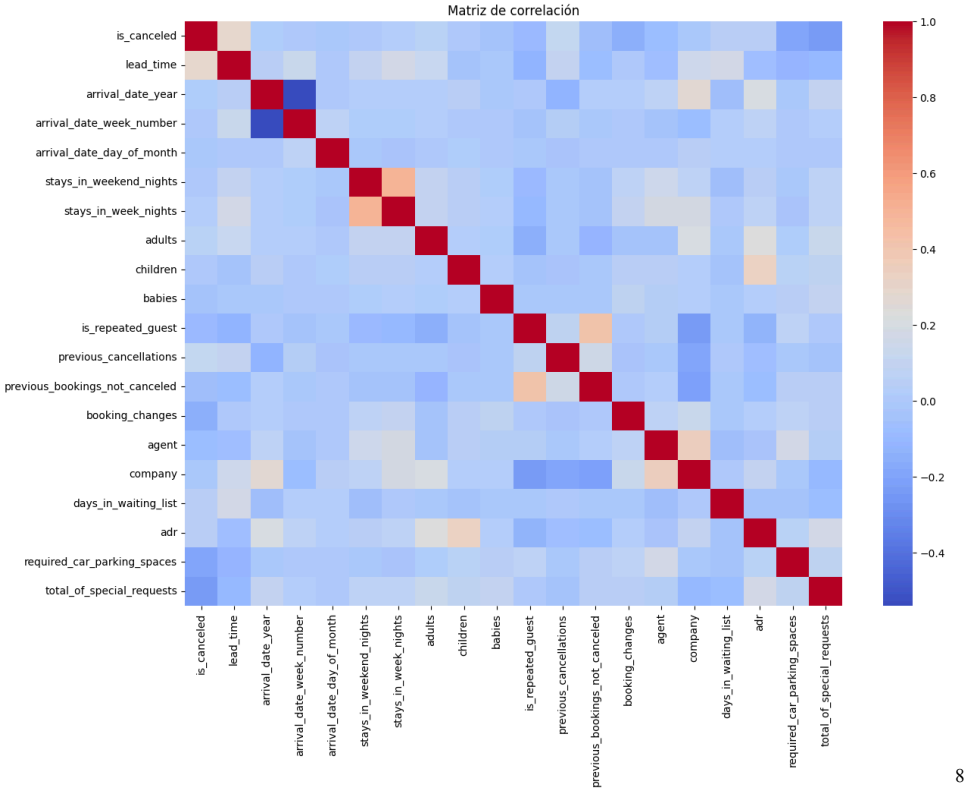
[7]

La variable objetivo presenta un cierto desbalance de clases, aunque no es extremo. Existe una mayor proporción de reservas no canceladas frente a canceladas.

[7] Pie Chart del balanceo de clases de la variable objetivo "is_canceled"

2.5. Exploración de relaciones entre variables mediante correlaciones

Realizamos una matriz de correlaciones con código de colores para ver mejor gráficamente la relación que existe entre la variable objetivo y las diferentes variables numéricas.



8

Las variables que presentan mayor relación positiva con la cancelación ("is_canceled") son:

- lead_time (0.29)

  → Es la variable más relevante. Cuanto mayor es el tiempo entre la reserva y la llegada, mayor es la probabilidad de cancelación.

- previous_cancellations (0.11)

  → Clientes con historial de cancelaciones tienen mayor probabilidad de cancelar de nuevo.

- adults (0.06) y days_in_waiting_list (0.05)

  → Relación positiva débil.

[8] Matriz de correlación entre variable objetivo y el resto de variables numéricas

- adr (0.047)
  → Ligera relación positiva: precios más altos podrían asociarse a mayor probabilidad de cancelación.

Por otro lado, las variables con correlación negativa más destacadas son:

- total_of_special_requests (-0.23)
  → A mayor número de peticiones especiales, menor probabilidad de cancelación (clientes más comprometidos).
- required_car_parking_spaces (-0.20)
  → Clientes que solicitan parking tienen menor probabilidad de cancelar.
- booking_changes (-0.14)
  → Más cambios en la reserva pueden indicar mayor intención de mantenerla.
- is_repeated_guest (-0.08)
  → Clientes recurrentes cancelan menos.

Se observan algunas correlaciones entre variables explicativas:

- stays_in_week_nights y stays_in_weekend_nights presentan cierta correlación positiva, ya que ambas reflejan la duración de la estancia.
- previous_cancellations y previous_bookings_not_canceled muestran cierta relación, al estar ambas vinculadas al historial del cliente.

En general, no se detectan correlaciones muy altas entre variables independientes, lo que reduce el riesgo de multicolinealidad.

Este análisis solo incluye variables numéricas, ya que las variables categóricas no pueden analizarse directamente mediante correlación de Pearson. Estas serán tratadas posteriormente mediante técnicas de codificación (encoding).

4. Limpieza y preparación de los datos

Una vez se han analizado todas las variables y se han tomado las decisiones necesarias, lo pasamos a la práctica a través de comandos para limpiar la base de datos. Las decisiones son:

- Eliminar variables no relevantes como 'company' y 'agent'
- Eliminar inconsistencias expuestas (por ej. Reservas sin huéspedes)
- Eliminar outlier extremo de ADR
- Creación de una nueva variable room_changed: presenta un 1 cuando el valor de la habitación seleccionada en la reserva no coincide con el valor asignado.
- Eliminar variables que aportan overfitting como reservation_status y reservation_status_date
- Agrupar categorías poco frecuentes en 'country'.
- Escalar los datos para evitar desfases.

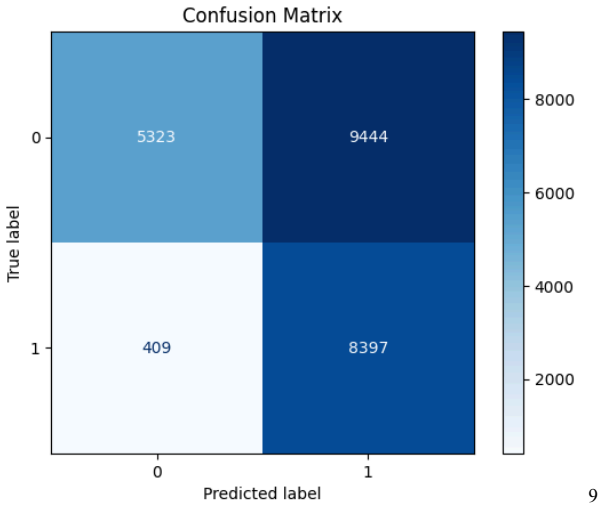
Se nos queda un dataset de dimensiones: 117863 observaciones x 25 variables.
A continuación, hacemos el encoding de las variables con dummies y hacemos una división de la muestra para test y train con un tamaño de test del 20% y de train del 80% restante.

5. Algoritmos empleados

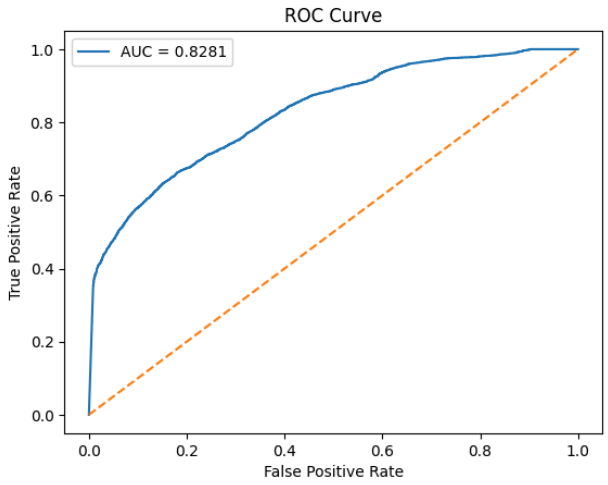
A continuación se muestra una lista con los algoritmos de predicción elegidos y entrenados, junto a una evaluación del modelo, basada en matrices de confusión, curvas roc y principales métricas.

a. Naive Bayes

Comenzamos con un modelo de Naive Bayes. En este, a diferencia del resto, no aplica validación cruzada al no haber hiper parámetros que variar. Utiliza probabilidades y el teorema de Bayes. Al no estar muy correlacionadas las variables y este asumir la independencia entre ellas, es correcto su uso. Las métricas obtenidas son las siguientes:



9



10

```
=== Main Metrics ===
Accuracy    = 0.5820
Precision   = 0.4707
Recall      = 0.9536
F1-score    = 0.6302
Specificity = 0.3605
```

```
=== ROC Curve ===
ROC-AUC     = 0.8281
```

Como podemos observar, las métricas son muy bajas, con una especificidad (número de positivos bien predecidos) muy baja, del 36%. El valor de AUC de 83% aproximadamente es un poco mejor.

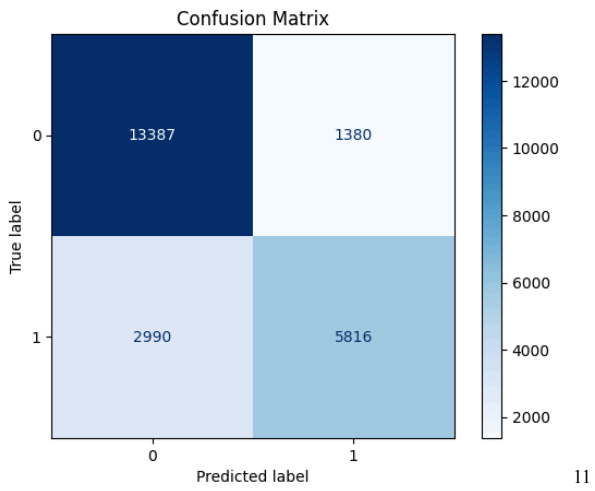
b. Regresion logistica

La regresión logística es un método de clasificación a través de una probabilidad de 0 a 1. Si esta probabilidad es mayor que 0.5, la clase será la 1, sino, clase 0. En el caso de la regresión logística, hacemos uso de validación cruzada para elegir el hiper parámetro C. Este parámetro controla la regularización al ser su inverso. Controla el equilibrio entre ajuste y simplicidad. Al hacer el GridSearch obtenemos un C óptimo de 10.

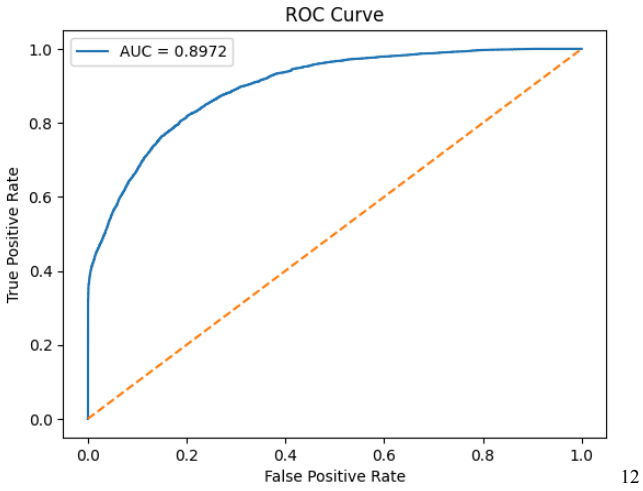
[9] Matriz de Confusión Naive Bayes
[10] Curva ROC Naive Bayes

Se ha utilizado tanto en Logística como en KNN validación cruzada con 5 particiones (cv=5), lo que implica dividir los datos de entrenamiento en cinco subconjuntos. El modelo se entrena cinco veces utilizando cuatro subconjuntos para entrenamiento y uno para validación, promediando los resultados para obtener una estimación más robusta del rendimiento.

Si eliges C pequeño el modelo penaliza más los coeficientes grandes. Los pesos tienden a ser más pequeños. Modelo más simple, menos overfitting, pero puede subajustar.
Si eliges C grande la penalización es más débil. Los coeficientes pueden crecer más. Modelo más flexible, puede capturar más patrones, pero riesgo de overfitting
En este caso, C = 10 implica una fuerza de regularización de 0.10, relativamente baja. Nos encontramos en el caso de C grande, con un modelo más flexible.



11



12

```
=== Main Metrics ===
Accuracy    = 0.8146
Precision   = 0.8082
Recall      = 0.6605
F1-score    = 0.7269
Specificity = 0.9065
```

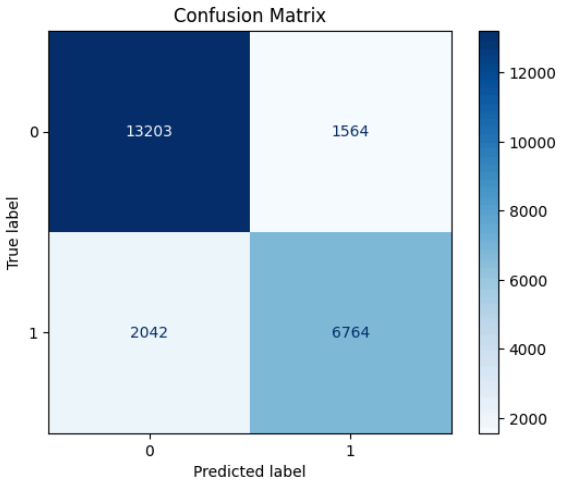
```
=== ROC Curve ===
ROC-AUC     = 0.8972
```

En este caso, la matriz de confusión muestra mejores resultados que anteriormente además de un AUC mayor.

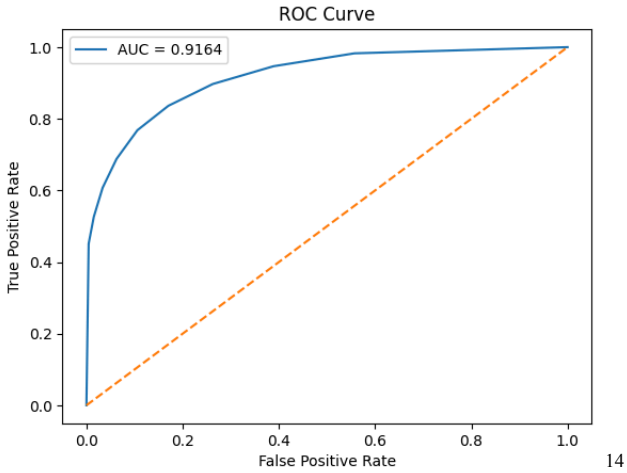
[11] Matriz de confusión Regresión Logística
[12] Curva ROC Regresión Logística

c. KNN

El modelo KNN (k-nearest neighbors) clasifica un dato según la clase más común entre sus k vecinos más cercanos en el espacio de características. Para este seguimos el mismo patrón de estimación del mejor hiper parámetro y validación cruzada que en Logística. Se obtiene un número de vecinos igual a 9.



13



14

```
=== Main Metrics ===
Accuracy    = 0.8470
Precision   = 0.8122
Recall      = 0.7681
F1-score    = 0.7895
Specificity = 0.8941
```

```
=== ROC Curve ===
ROC-AUC     = 0.9164
```

Aumentamos el valor de la curva ROC y las métricas también son muy positivas.

d. Árbol de decisión CART

CART (Classification and Regression Trees) es un modelo que construye un árbol de decisión dividiendo los datos en reglas binarias para predecir una clase o valor.

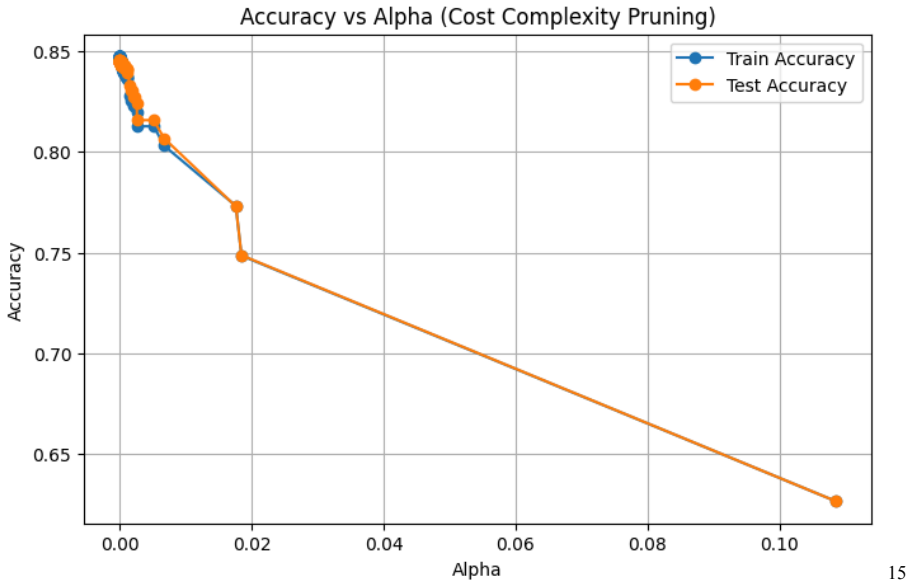
Los modelos basados en árboles de decisión no requieren normalización de las variables, ya que no dependen de distancias ni de la escala de los datos, sino de reglas de decisión basadas en comparaciones. Sin embargo, en este proyecto se ha optado por utilizar el dataset previamente

[13] Matriz de confusión KNN
[14] Curva ROC KNN

normalizado también para estos modelos, con el objetivo de mantener la coherencia en el preprocesamiento y facilitar la comparación entre distintos algoritmos.

Dado que la normalización no afecta al funcionamiento de los árboles, esta decisión no perjudica el rendimiento del modelo.

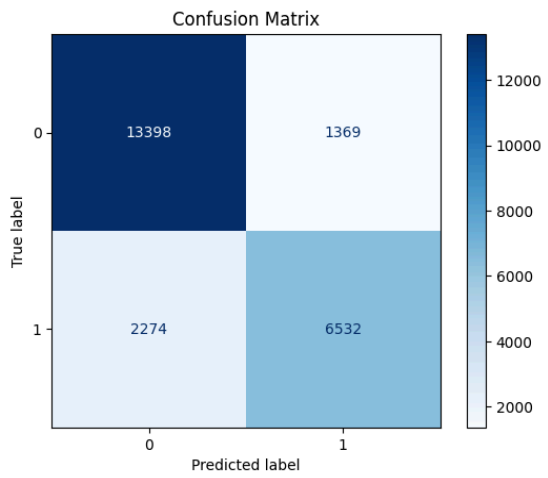
Se utiliza un cost-complexity pruning path para decidir el valor de alpha necesario.



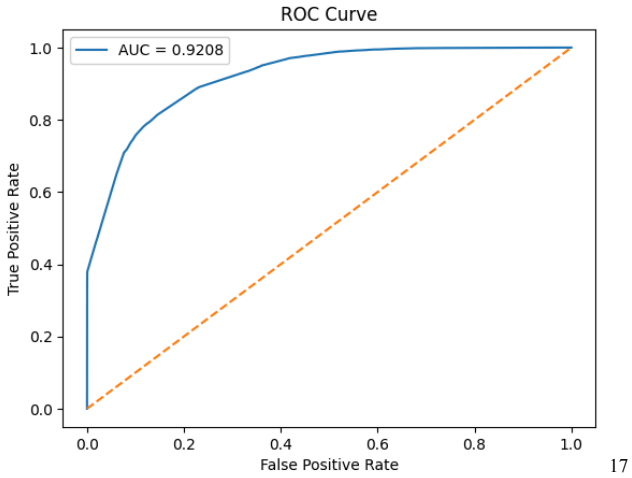
[15]

La gráfica muestra cómo, a partir de un total de 163 valores de α generados, el modelo pasa de un árbol muy complejo (α cercano a 0) con alta precisión, a árboles más simples cuya precisión disminuye progresivamente, evidenciando subajuste para valores grandes de α. Se observa que las curvas de entrenamiento y test son similares en la zona inicial, lo que indica buena generalización y ausencia de sobreajuste significativo. Por ello, se ha seleccionado α = 4.148764354684753e-05, ya que se encuentra en la región donde la precisión de test es cercana al máximo y el modelo mantiene un equilibrio adecuado entre complejidad y capacidad predictiva.

[15] Cost-complexity pruning path CART



16



17

```
=== Main Metrics ===

Accuracy    = 0.8455

Precision   = 0.8267

Recall      = 0.7418

F1-score    = 0.7819

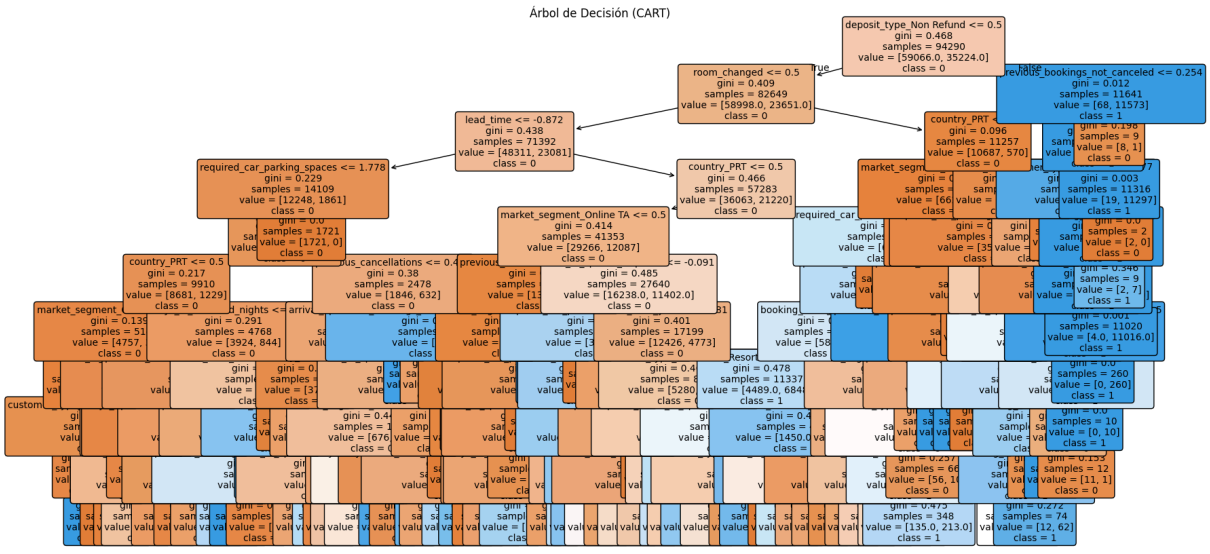
Specificity = 0.9073
```

```
=== ROC Curve ===

ROC-AUC     = 0.9208
```

Podemos ver unos valores de AUC y métricas muy buenos.

También aprovechamos para mostrar gráficamente el árbol CART del modelo final.



18

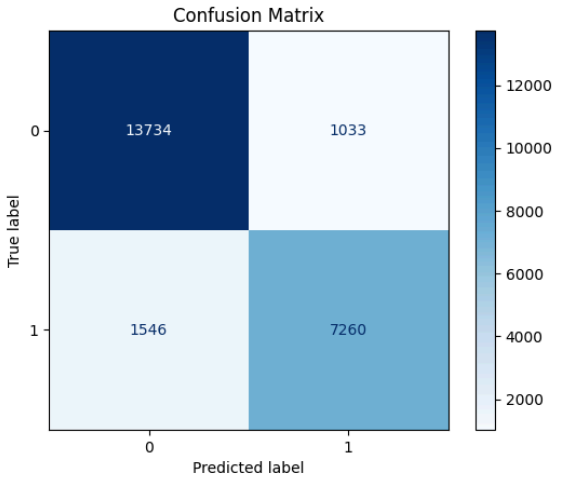
[16] Matriz de confusión CART
[17] Curva ROC CART
[18] Árbol de decisión CART

e. Ensemble

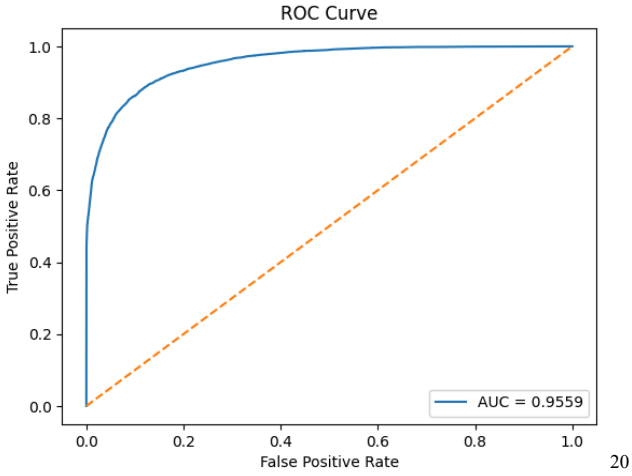
El método ensemble es una técnica de aprendizaje automático que combina varios modelos (como árboles o redes) para obtener una predicción más precisa y robusta que la de un solo modelo, ya que aprovecha la colectividad y reduce errores individuales.

i. Bagging: Random Forest (CART)

El bagging es una técnica de aprendizaje automático que entrena varios modelos con muestras distintas y promedia sus resultados para mejorar la precisión. Random Forest es bagging aplicado a árboles de decisión, combinando muchos árboles para hacer predicciones más estables y fiables. Se ha hecho una búsqueda de los mejores parámetros de depth, estimadores y split.



19



20

```
=== Main Metrics ===
Accuracy    = 0.8906
Precision   = 0.8754
Recall      = 0.8244
F1-score    = 0.8492
Specificity = 0.9300
```

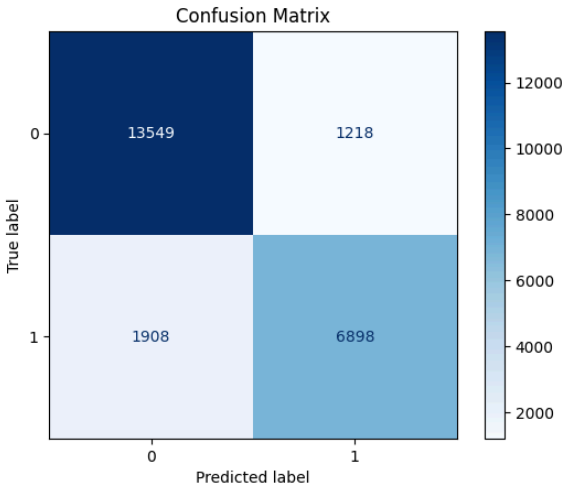
```
=== ROC Curve ===
ROC-AUC     = 0.9559
```

Se obtiene el mejor resultado de AUC hasta ahora y la mayoría de las mejores medidas.

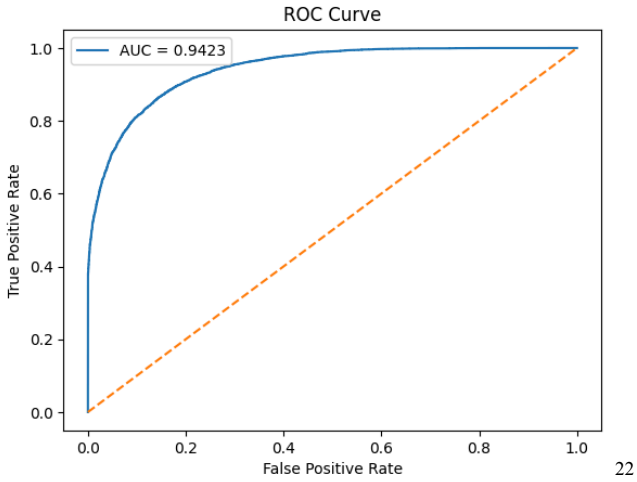
[19] Matriz de confusión Bagging Random Forest
[20] Curva ROC Bagging Random Forest

ii. Boosting: Gradient Boosting (CART)

El boosting es una técnica de aprendizaje automático que combina modelos en secuencia para corregir errores anteriores. Gradient Boosting lo hace ajustando esos errores de forma gradual para mejorar la precisión. Se estiman los mejores valores para sus parámetros depth, estimators y learning rate.



21



22

```
=== Main Metrics ===
Accuracy    = 0.8674
Precision   = 0.8499
Recall      = 0.7833
F1-score    = 0.8153
Specificity = 0.9175
```

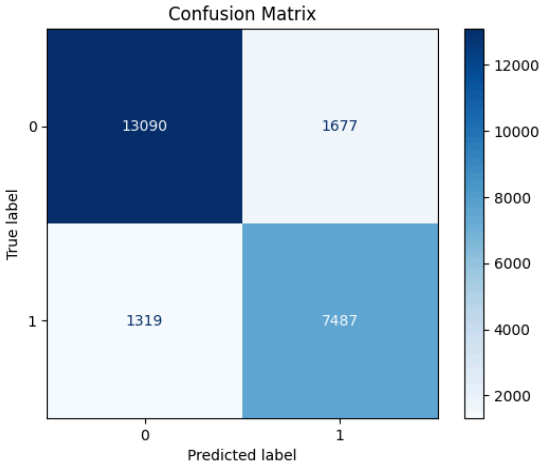
```
=== ROC Curve ===
ROC-AUC     = 0.9423
```

Podemos observar unos valores muy buenos en todas las métricas.

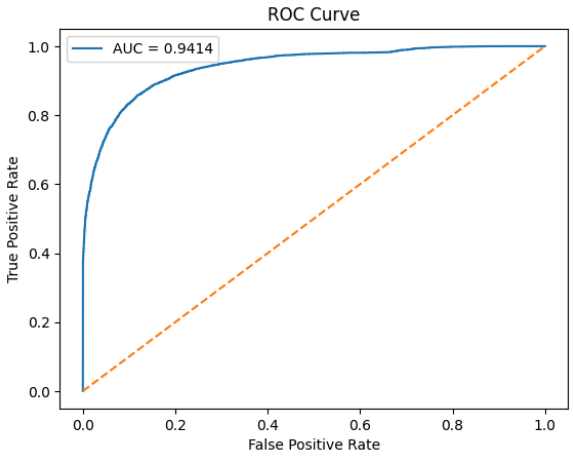
iii. Voting Soft (Votes)

El voting (soft) es una técnica de ensemble en aprendizaje automático donde varios modelos combinan sus predicciones promediando las probabilidades de cada clase y eligiendo la más alta, en lugar de votar solo por la clase final. En este se utilizan todos los modelos entrenados hasta ahora.

[21] Matriz de confusión Gradient Boosting
[22] Curva ROC Gradient Boosting



23



24

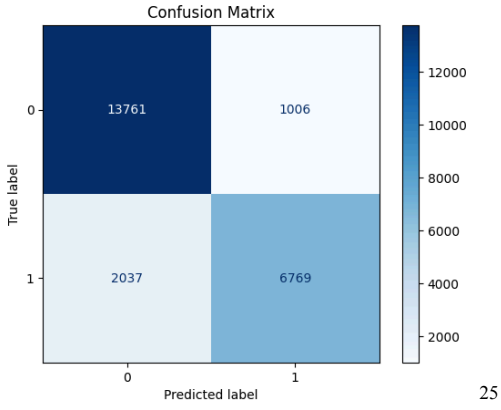
```
=== Main Metrics ===
Accuracy    = 0.8729
Precision   = 0.8170
Recall      = 0.8502
F1-score    = 0.8333
Specificity = 0.8864
```

```
=== ROC Curve ===
ROC-AUC     = 0.9414
```

Como observamos, seguimos obteniendo muy buenas métricas al ser un modelo tan completo.

iv. Voting Hard (Probabilities)

El Voting Hard Ensemble es un modelo que combina varios clasificadores y predice la clase final mediante la mayoría de votos de sus predicciones individuales. En este se utilizan también todos los modelos entrenados hasta ahora.



25

[23] Matriz de confusión de Voting Soft
[24] Curva ROC de Voting Soft
[25] Matric de confusión de Voting Hard

```
=== Main Metrics ===
Accuracy    = 0.8667
Precision   = 0.8397
Recall      = 0.7949
F1-score    = 0.8167
Specificity = 0.9095
```

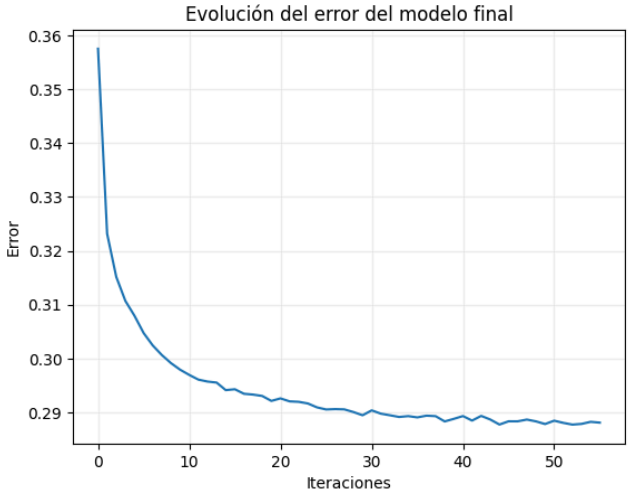
En este caso no es posible hallar la curva ROC ya que el modelo no predice probabilidades. En cuanto al resto de métricas, también son elevadas con un accuracy del 86.67%.

f. Redes Neuronales

Las redes neuronales son modelos de Machine Learning inspirados en el cerebro humano que aprenden patrones a partir de los datos ajustando conexiones (pesos) entre neuronas para minimizar el error de predicción.

El optimizador Adam es un método de entrenamiento muy usado en redes neuronales que mejora el ajuste de esos pesos combinando dos ideas: el momentum (para acelerar el aprendizaje en direcciones consistentes) y la adaptación del learning rate para cada parámetro, lo que permite un entrenamiento más estable y eficiente.

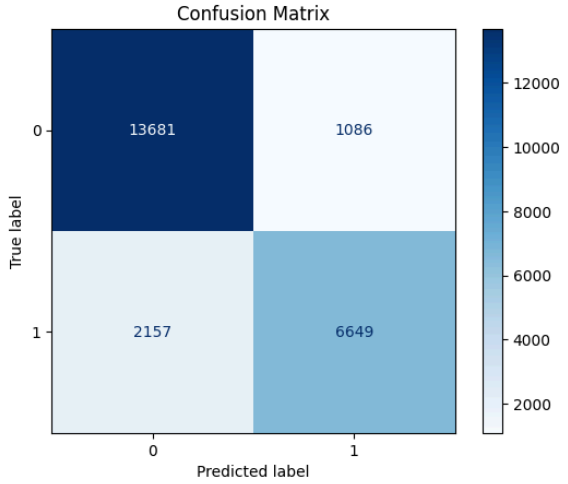
Hemos usado un GridSearch con validación cruzada para estimar sus parámetros hidden_layer_sizes y learning_rate_init.



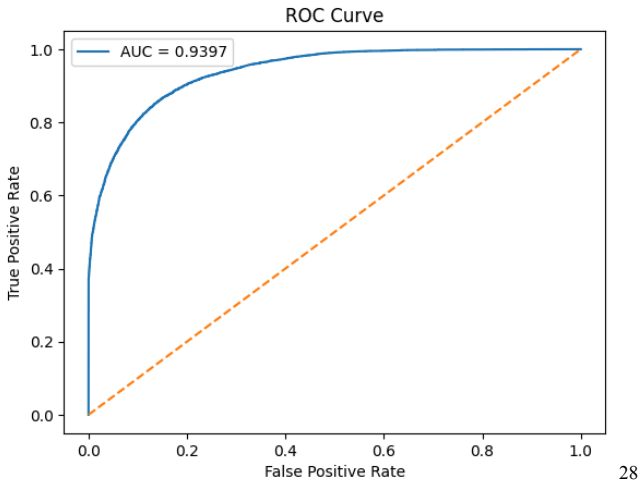
[26]

[26] Evolución del error en Redes Neuronales

La gráfica muestra cómo cambia el error del modelo a lo largo del proceso de entrenamiento. Como podemos ver, converge y por tanto llega un punto que el error ya no puede ser mejor. Las dimensiones de las matrices de pesos en las dos capas son de (52,20) y de (20,1).



27



28

```
=== Main Metrics ===
Accuracy    = 0.8624
Precision   = 0.8596
Recall      = 0.7551
F1-score    = 0.8039
Specificity = 0.9265
```

```
=== ROC Curve ===
ROC-AUC     = 0.9397
```

Las métricas son muy positivas también. Con una curva ROC con un valor de AUC muy elevado.

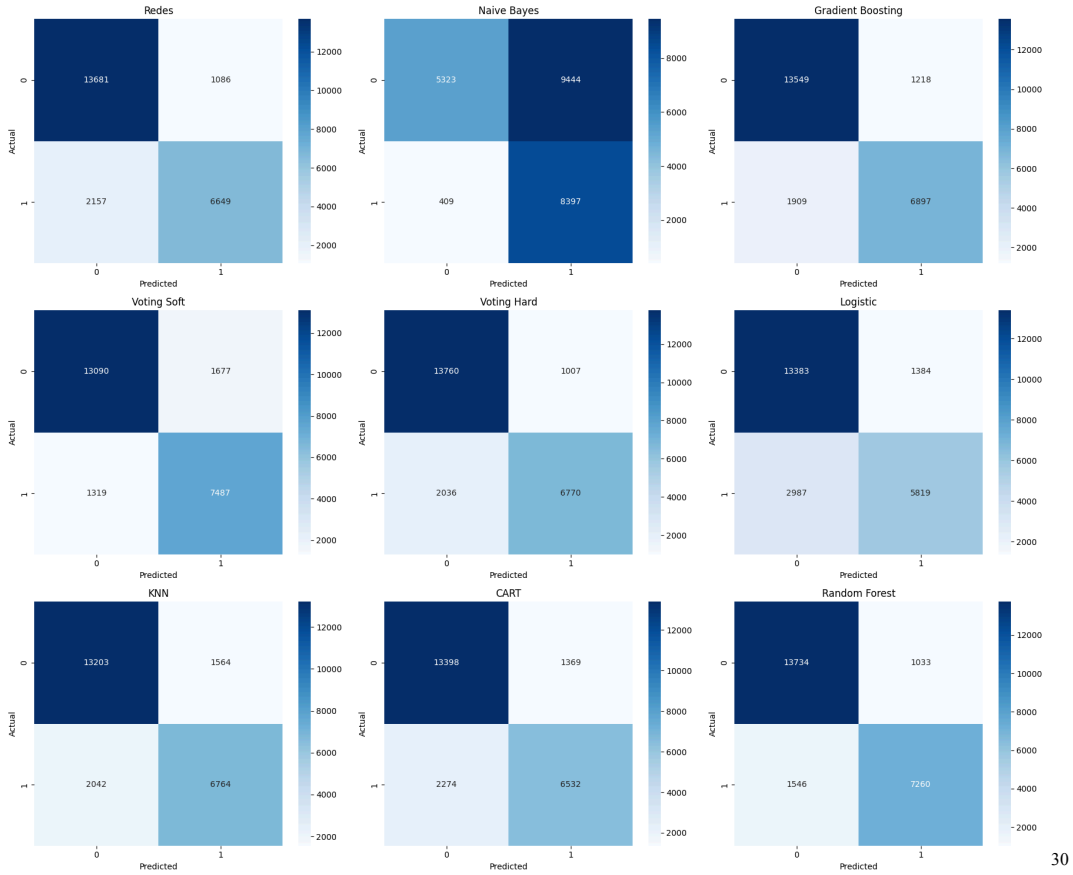
Comparación los modelos y elección del mejor modelo

Para elegir el mejor modelo hemos decidido hacer una tabla con todas las métricas para así ver cual de todos contaba con las mejores. Se muestra la tabla a continuación:

[27] Matriz de confusión de Redes Neuronales
[28] Curva ROC de Redes Neuronales

model	accuracy	precision	recall	F1	specificity	AUC
redes	0.862427	0.859599	0.755053	0.803942	0.926458	0.9397
nb	0.582022	0.470657	0.953554	0.630240	0.360466	0.828077
gb	0.867391	0.849926	0.783330	0.815270	0.917519	0.942313
vot	0.872905	0.817001	0.850216	0.833278	0.886436	0.941406
vot_hard	0.870912	0.870611	0.768680	0.816477	0.931875	No tiene
log	0.814618	0.808227	0.660459	0.726909	0.906548	0.897229
KNN	0.847028	0.812200	0.768113	0.789541	0.894088	0.916371
CART	0.845459	0.826731	0.741767	0.781948	0.907293	0.92078
rf	0.890595	0.875437	0.824438	0.849172	0.930047	0.955917

29



30

El modelo seleccionado como mejor es Random Forest (rf) porque presenta el mejor rendimiento global entre todas las métricas evaluadas. En particular, alcanza la mayor accuracy (0.8906), lo que indica una alta proporción de predicciones correctas en general. Además, destaca también en

[29] Tabla comparativa de métricas de modelos
[30] Matrices de confusión agrupadas

precisión (0.8754) y recall (0.8244), mostrando un buen equilibrio entre la capacidad de identificar correctamente las clases positivas y minimizar los falsos positivos. Su F1-score (0.8492) es el más alto del conjunto, lo que refuerza que mantiene un balance óptimo entre precisión y recall. Asimismo, presenta una specificity elevada (0.9300), lo que indica una buena capacidad para identificar correctamente los casos negativos. Finalmente, también obtiene el mejor AUC (0.9559), lo que refleja una excelente capacidad de discriminación entre clases. En conjunto, estas métricas justifican que Random Forest sea el modelo más robusto y fiable para este problema.

Explicabilidad e interpretabilidad del modelo Random Forest seleccionado como mejor modelo

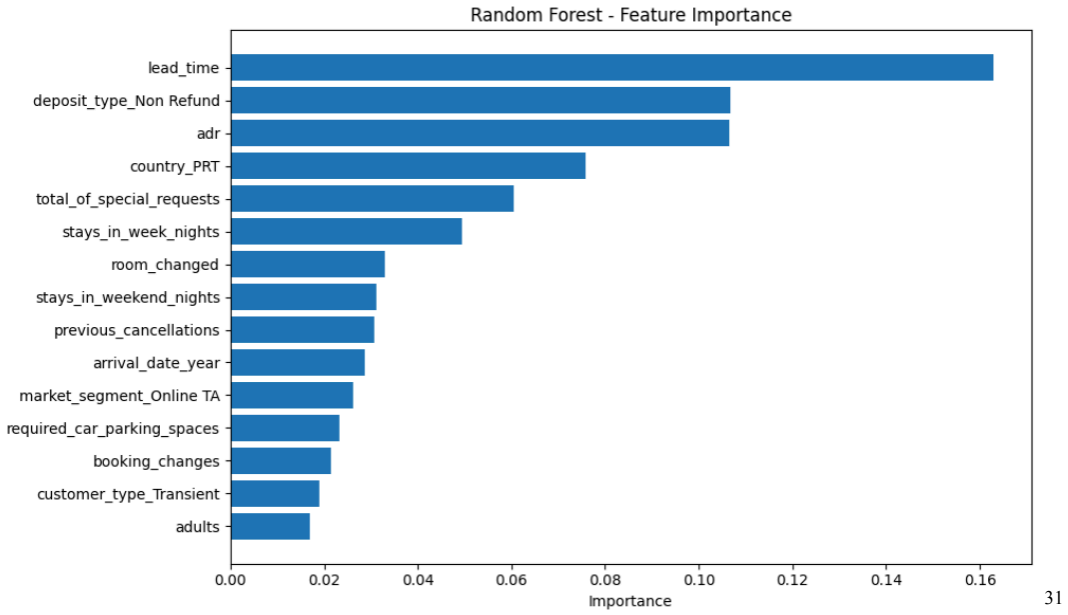
Como ya hemos observado el modelo Random Forest presenta un rendimiento sólido en la predicción de cancelaciones hoteleras. El buen rendimiento del modelo Random Forest puede explicarse por varios factores relacionados tanto con la naturaleza del problema como con las características del dataset utilizado. En primer lugar, el modelo se ha entrenado con un volumen muy elevado de datos (más de 90.000 observaciones en entrenamiento), lo que le permite capturar patrones complejos y generalizar adecuadamente al conjunto de test. En segundo lugar, el problema de predicción de cancelaciones hoteleras presenta relaciones no lineales entre las variables (como el efecto del lead_time, el tipo de depósito o el canal de reserva), que modelos como Random Forest son capaces de modelar eficazmente al combinar múltiples árboles de decisión. Además, el uso de variables bien procesadas (incluyendo codificación de variables categóricas y normalización de variables numéricas) contribuye a que el modelo disponga de información clara y estructurada. Por último, el carácter ensemble del Random Forest, que promedia las predicciones de muchos árboles, reduce el riesgo de overfitting y mejora la estabilidad del modelo, lo que se traduce en un alto nivel de precisión y una excelente capacidad de discriminación, como refleja el elevado valor del AUC obtenido.

Aunque el modelo Random Forest presenta un rendimiento muy elevado en términos de precisión y capacidad predictiva, esto por sí solo no es suficiente desde un punto de vista empresarial. En problemas como la predicción de cancelaciones hoteleras, no solo es importante

saber qué reservas tienen mayor probabilidad de cancelarse, sino también entender por qué el modelo toma esas decisiones. En este contexto, entran en juego los conceptos de interpretabilidad y explicabilidad. La interpretabilidad permite comprender el funcionamiento interno del modelo y la relación entre variables, mientras que la explicabilidad se centra en justificar cada predicción de forma clara y comprensible para el usuario final. Esto aporta un valor clave en negocio, ya que permite generar confianza en el modelo, identificar los factores que impulsan las cancelaciones y, sobre todo, transformar las predicciones en acciones concretas. Por ello, a continuación se detallarán estos aspectos.

1. **Feature Importance; explicación de las variables que considera el modelo más importantes**

El análisis de importancia de variables del Random Forest muestra que las variables más influyentes en la predicción son lead_time (0.1629), deposit_type_Non Refund (0.1068), adr (0.1064) y country_PRT (0.0759). Esto indica que el tiempo de antelación con el que se realiza la reserva, el tipo de depósito, el precio medio diario y el país de origen del cliente son factores clave en la predicción de cancelaciones.



[31]

[31] Importancia de las variables (feature importance)

2. **Permutation importance : observamos cuanto empeora el accuracy**

El análisis de permutation importance confirma y refuerza los resultados anteriores desde una perspectiva más robusta, ya que mide el impacto de cada variable en el rendimiento del modelo. En este caso, las variables más relevantes son total_of_special_requests (0.0733), lead_time (0.0547) y country_PRT (0.0407). Esto significa que al desordenar estas variables, el accuracy del modelo disminuye significativamente, lo que evidencia su importancia en la predicción. Destaca especialmente total_of_special_requests, indicando que el número de peticiones especiales del cliente es un factor clave para distinguir entre reservas que se cancelan y las que no.

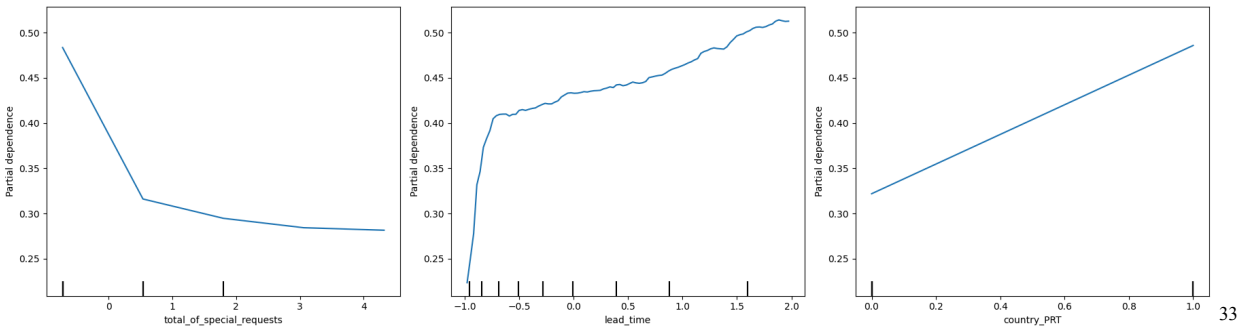
	feature	importance_mean
14	total_of_special_requests	0.073333
0	lead_time	0.054667
36	country_PRT	0.040667
42	market_segment_Online TA	0.037333
47	deposit_type_Non Refund	0.031333
15	room_changed	0.020000
13	required_car_parking_spaces	0.012000
50	customer_type_Transient	0.011333
1	arrival_date_year	0.010667
35	country_Other	0.008667
16	hotel_Resort Hotel	0.008667
12	adr	0.008667
8	previous_cancellations	0.007333
21	arrival_date_month_July	0.004667
51	customer_type_Transient-Party	0.004000

[32]

3. **PDP (Partial Dependence Plots): efecto medio de variables mas importantes**

Los gráficos PDP permiten analizar el efecto medio de las variables sobre la probabilidad de cancelación. En el caso de total_of_special_requests, se observa una relación decreciente: a medida que aumentan las peticiones especiales, disminuye la probabilidad de cancelación, lo que sugiere que clientes más implicados son menos propensos a cancelar. Por otro lado, el PDP de lead_time muestra una tendencia creciente, indicando que cuanto mayor es la antelación de la reserva, mayor es la probabilidad de cancelación. Finalmente, en country_PRT se observa que los clientes procedentes de Portugal presentan una mayor probabilidad media de cancelación

[32] Importancia de las variables (Permutation importance)



[33]

4. SHAP Local

El shap local nos sirve para explicar una observación concreta en este caso de reserva cancelada. Imaginemos que estamos analizando la reserva de un cliente concreto. El modelo predice que esta reserva será cancelada con una probabilidad muy alta del 96.17%, partiendo de una probabilidad media del modelo de 0.373. A partir de ahí, cada característica del cliente va empujando esa probabilidad hacia arriba o hacia abajo.

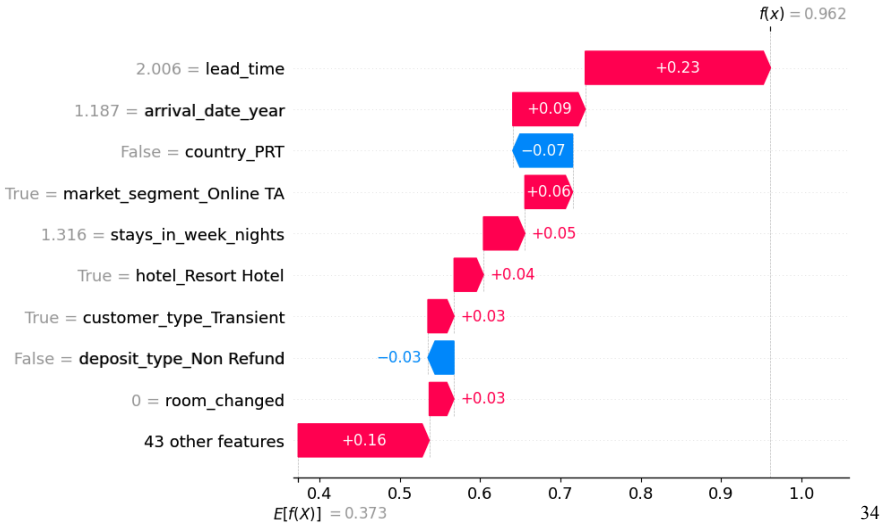
En este caso, el cliente tiene un valor de lead_time de 2.006, que al estar normalizado significa que su reserva se hizo con mucha más antelación de lo habitual (muy por encima de la media). Esto es el factor más importante y aumenta la probabilidad de cancelación en +0.23, lo que tiene sentido porque reservas con mucha antelación suelen ser más inestables. Además, arrival_date_year tiene un valor de 1.187, lo que indica que pertenece a un año concreto que, según el modelo, está asociado a más cancelaciones, aportando +0.09 a la predicción.

El cliente pertenece al segmento market_segment_Online TA = True, es decir, ha reservado a través de una agencia online, lo que incrementa la probabilidad de cancelación en +0.06. También tiene stays_in_week_nights = 1.316 (más noches entre semana que la media), lo que añade +0.05, y hotel_Resort Hotel = True, indicando que la reserva es en un resort, lo que suma +0.04. Además, es un cliente tipo Transient (customer_type_Transient = True), lo que aporta +0.03, y no ha cambiado de habitación (room_changed = 0), lo que añade otros +0.03.

[33] PDP variables mas importantes

Por otro lado, hay factores que reducen ligeramente la probabilidad de cancelación. Por ejemplo, country_PRT = False indica que el cliente no es de Portugal, lo que reduce la probabilidad en -0.07, y deposit_type_Non Refund = False indica que la reserva no es no reembolsable, lo que también reduce ligeramente la probabilidad en -0.03.

Finalmente, el resto de variables (agrupadas como "43 other features") aportan en conjunto +0.16, reforzando aún más la predicción de cancelación. En conjunto, aunque existen algunos factores que reducen la probabilidad, el efecto dominante de variables como la alta antelación de la reserva, el canal online y el tipo de cliente hacen que el modelo esté muy seguro de que esta reserva será cancelada.

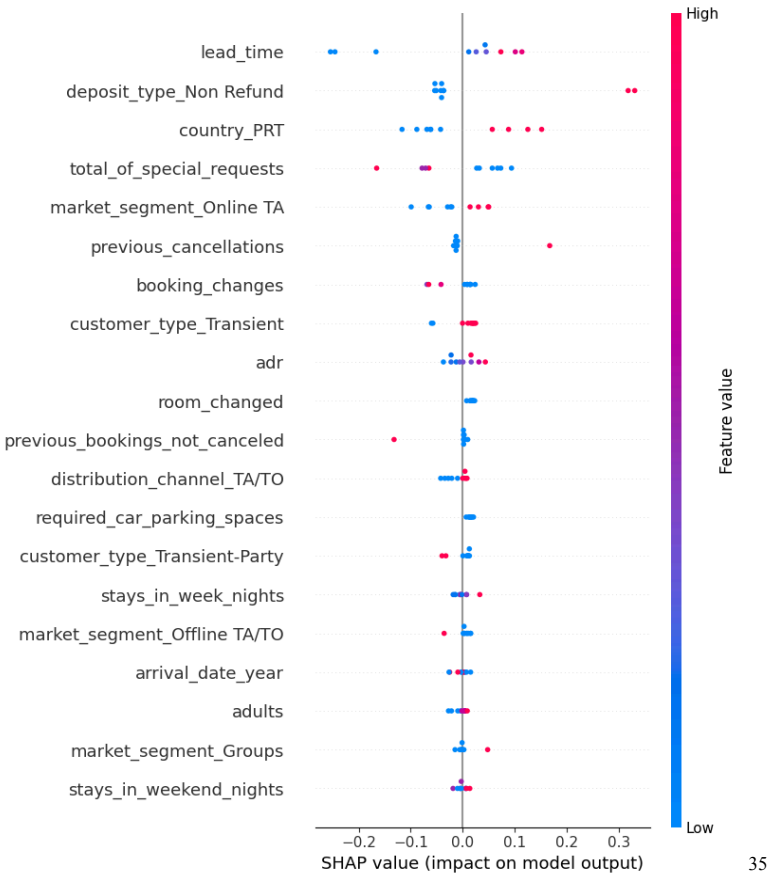


34

5. SHAP Global

El análisis SHAP global, aunque realizado sobre una muestra reducida para evitar altos costes computacionales, muestra resultados consistentes con los análisis anteriores. Las variables con mayor impacto medio en la predicción son lead_time, deposit_type_Non Refund , country_PRT, total_of_special_requests y market_segment_Online TA. El summary plot permite además observar no solo la importancia de las variables, sino también la dirección de su efecto: por ejemplo, valores altos de lead_time tienden a aumentar la probabilidad de cancelación, mientras que valores altos de total_of_special_requests tienden a reducirla. En conjunto, este análisis confirma los patrones detectados previamente y proporciona una visión más detallada del comportamiento del modelo

[34] Gráfica SPAP local para una observación cancelada



35

Resultados e interpretación

A lo largo del trabajo se ha desarrollado un proceso completo de análisis predictivo para la cancelación de reservas hoteleras, comenzando con un análisis exploratorio que permitió depurar los datos y detectar que la cancelación responde a patrones concretos del comportamiento del cliente y de la reserva. Posteriormente, se compararon distintos modelos de clasificación, seleccionando Random Forest como el mejor por su equilibrio entre rendimiento e interpretabilidad.

El modelo alcanza una accuracy de 0.8906, con 13.734 verdaderos negativos, 7.260 verdaderos positivos, 1.033 falsos positivos y 1.546 falsos negativos, mostrando mejor capacidad para identificar no cancelaciones que cancelaciones. Las métricas (precisión 0.8754, recall 0.8244, F1 0.8492 y AUC 0.9559) confirman una excelente capacidad predictiva. Desde el punto de vista de

[35] SHAP Global

negocio, esto permite anticipar cancelaciones con fiabilidad y pasar de una gestión reactiva a una preventiva.

En cuanto a la explicabilidad, los análisis globales (feature importance y permutation importance) identifican como variables clave lead_time, total_of_special_requests, country_PRT y deposit_type_Non Refund. Los PDP muestran que una mayor antelación aumenta la probabilidad de cancelación, mientras que un mayor número de peticiones especiales la reduce, reflejando el nivel de compromiso del cliente. A nivel local, SHAP permite explicar casos individuales, mostrando cómo variables como lead_time o el canal de reserva impulsan el riesgo de cancelación. En conjunto, todos los análisis coinciden en que la cancelación está asociada a la antelación de la reserva, el compromiso del cliente y las condiciones de la misma, aportando no solo capacidad predictiva sino también una comprensión útil para la toma de decisiones.

Comparación con la propuesta inicial

El desarrollo del proyecto ha seguido en gran medida la línea planteada en la propuesta inicial, cumpliendo tanto los objetivos generales como la metodología prevista. Desde el inicio se planteó la construcción de un modelo predictivo para la cancelación de reservas hoteleras mediante técnicas de Machine Learning, objetivo que se ha alcanzado satisfactoriamente .

En cuanto a la metodología, se han seguido las fases propuestas: análisis exploratorio de datos (EDA), preprocesamiento, selección de variables, entrenamiento de modelos y evaluación mediante métricas como accuracy, precisión, recall y F1-score . No obstante, **el trabajo final ha ido más allá de lo inicialmente planteado, incorporando un análisis más profundo y riguroso, debido a la incorporación de nuevo temario en la asignatura**. Por ejemplo, se han aplicado técnicas adicionales como modelos ensemble (Random Forest, Gradient Boosting y Voting) y redes neuronales, que no estaban desarrolladas con tanto detalle en la propuesta inicial pero han resultado clave en la mejora del rendimiento .

Asimismo, se ha realizado un análisis más avanzado en términos de interpretabilidad del modelo, incorporando herramientas como feature importance, permutation importance, PDP y SHAP.

Este aspecto supone una mejora significativa respecto a la propuesta inicial, donde la interpretabilidad se planteaba de forma más general.

En relación con los resultados esperados, se ha cumplido el objetivo de obtener un modelo con alta capacidad predictiva, destacando el modelo Random Forest como el más eficiente, con métricas superiores al resto de algoritmos . Además, se ha logrado transformar estos resultados en conclusiones útiles desde el punto de vista empresarial, tal y como se planteaba inicialmente.

En conclusión, el trabajo no solo cumple con lo propuesto inicialmente, sino que lo amplía y mejora, incorporando técnicas más avanzadas, un análisis más profundo y una mayor orientación a la aplicabilidad en el ámbito empresarial.

Conclusiones y recomendaciones

Los resultados obtenidos **no deben entenderse únicamente como un ejercicio técnico, sino como una herramienta clave para la toma de decisiones en la gestión hotelera**. La capacidad de anticipar cancelaciones permite al hotel actuar de forma preventiva, reduciendo tanto el impacto económico como la incertidumbre operativa. En este sentido, el modelo puede utilizarse como un sistema de alerta temprana para identificar reservas con mayor riesgo y aplicar medidas específicas antes de que se produzca la cancelación.

Una de las principales aplicaciones es **la segmentación de reservas** según su nivel de riesgo. Las reservas de bajo riesgo pueden seguir el proceso habitual, mientras que las de alto riesgo pueden gestionarse de forma más activa mediante recordatorios, confirmaciones adicionales o comunicaciones personalizadas orientadas a reforzar el compromiso del cliente. Asimismo, **el tipo de depósito y las condiciones de cancelación pueden adaptarse según el riesgo estimado**, aplicando políticas más flexibles o incentivando opciones no reembolsables, siempre evitando medidas excesivamente restrictivas que puedan perjudicar la experiencia del cliente.

El análisis de variables clave aporta además líneas de actuación concretas. Por ejemplo, el alto impacto de lead_time indica que las reservas realizadas con mucha antelación son más inestables, lo que sugiere la n**ecesidad de realizar un seguimiento más activo de este tipo de**

clientes. Por otro lado, el efecto de total_of_special_requests muestra que un mayor nivel de implicación reduce la probabilidad de cancelación, lo que abre la puerta a **estrategias de engagement basadas en la personalización de la experiencia**. Además, el canal de reserva (market_segment_Online TA) revela que el comportamiento varía según el origen de la reserva, lo que permite adaptar la estrategia comercial y de comunicación a cada canal.

En cuanto a variables como el país de origen, es fundamental hacer un uso responsable. Aunque el modelo detecte diferencias de comportamiento entre mercados, **estas no deben utilizarse para discriminar clientes individualmente**, sino únicamente para análisis agregados, planificación de demanda o diseño de campañas específicas por mercado, garantizando siempre un enfoque ético y no discriminatorio.

En términos generales, **el modelo debe utilizarse como una herramienta de apoyo a la decisión y no como un sistema automático**. La clave no es penalizar reservas de alto riesgo, sino gestionarlas mejor mediante protocolos diferenciados. Además, la capacidad de anticipar cancelaciones permite mejorar la planificación de ocupación, ajustar estrategias de precios y optimizar el revenue management, impactando directamente en ingresos y eficiencia operativa.

Finalmente, como línea futura, **sería recomendable monitorizar el modelo de forma continua y evaluar su rendimiento en términos de coste de negocio, ya que no todos los errores tienen el mismo impacto**. En conclusión, el principal valor del modelo radica en transformar la predicción en acción: segmentar reservas, mejorar la comunicación, personalizar la experiencia y optimizar la gestión hotelera, siempre bajo un enfoque responsable y centrado en el cliente.