Machine Learning aplicado a la predicción de cancelaciones hoteleras

PROPUESTA DE PROYECTO PRÁCTICO FINAL

Isabel Alonso Casas

Bibiana Dorado Mateos

Machine Learning I: Fundamentos y Aprendizaje Supervisado

Universidad Pontificia Comillas, ICAI

Profesor: Miguel Ángel Sanz Bobi

18 de marzo de 2026

COMILLAS UNIVERSIDAD PONTIFICIA ICAI

ÍNDICE

Introducción y motivación 3

Objetivo y necesidades 4

Metodología de trabajo y técnicas previstas a utilizar 6

Recursos a emplear 8

Resultados esperados alcanzar 9

Introducción y motivación

El objetivo del presente proyecto es desarrollar un modelo predictivo basado en técnicas de Machine Learning que permita anticipar la cancelación de reservas hoteleras a partir de información disponible en una base de datos del sector.

En la actualidad, la industria hotelera opera en un entorno competitivo y digitalizado, donde la gestión eficiente de la demanda es clave para poder maximizar los ingresos. En este contexto, la cancelación de reservas constituye un problema relevante para la gestión de ingresos y la planificación operativa. Las cancelaciones generan incertidumbre en la ocupación futura del hotel y pueden provocar pérdidas económicas derivadas de:

- Habitaciones que quedan finalmente vacías.
- Sobrecostes operativos.
- Decisiones ineficientes de precios.

Ante esta problemática, el desarrollo de herramientas de analítica predictiva permite a los establecimientos hoteleros identificar patrones de comportamiento y anticipar la probabilidad de cancelación, mejorando así la toma de decisiones estratégicas.

Desde un punto de vista metodológico, el problema abordado se enmarca en una clasificación binaria, donde el objetivo principal es determinar si una reserva será cancelada o no a partir de un conjunto de variables explicativas.

El proyecto se orienta de forma general a aplicar técnicas aprendidas de Machine Learning para este análisis, evaluando de esta manera su utilidad en un problema real del ámbito empresarial. Usaremos estas técnicas por su capacidad para detectar patrones complejos a través del uso de Big Data.

A través de los resultados obtenidos, se podrán crear estrategias de retención o ajustes de pricing en empresas que se enfrenten a este problema.

Objetivo y necesidades

El objetivo general del proyecto es el desarrollo de un modelo de Machine Learning capaz de predecir la cancelación de reservas hoteleras a partir de datos históricos, con el fin de mejorar la toma de decisiones en el ámbito de la gestión hotelera.

Para poder desarrollar el proyecto tendremos que realizar los siguientes objetivos más específicos:

- Analizar y comprender la base de datos seleccionada y sus variables a través de un Análisis Exploratorio de Datos (EDA) inicial.
- Identificar los problemas posibles en los datos, como outliers o valores perdidos a la vez que estudiar si podría ser un problema el desbalance de clases.
- Tras el procesado de datos, implementar y entrenar distintos métodos de clasificación para predecir si una reserva será cancelada o no.
- Identificar las variables más relevantes que influyen en la cancelación.
- Comparar el rendimiento de distintos algoritmos para determinar cuál ofrece mejores resultados predictivos.
- Interpretar los resultados obtenidos y sacar conclusiones relevantes para el sector.

Este enfoque permitirá demostrar la utilidad del Machine Learning aplicado a problemas reales del ámbito empresarial, concretamente en la optimización de la gestión de reservas en el sector hotelero.

En cuanto a lo que necesidades se refiere, podemos diferenciar los siguientes subapartados:

a) **Necesidades de datos:** Para poder llevar a cabo el análisis necesitaremos de una base de datos representativa del comportamiento real de los clientes. Las variables deberán ser relevantes y numerosas. Debemos contar con suficiente volúmen de datos para entrenar los modelos. Estos datos tienen que ser de calidad, sin gran cantidad de valores inconsistentes o vacíos.

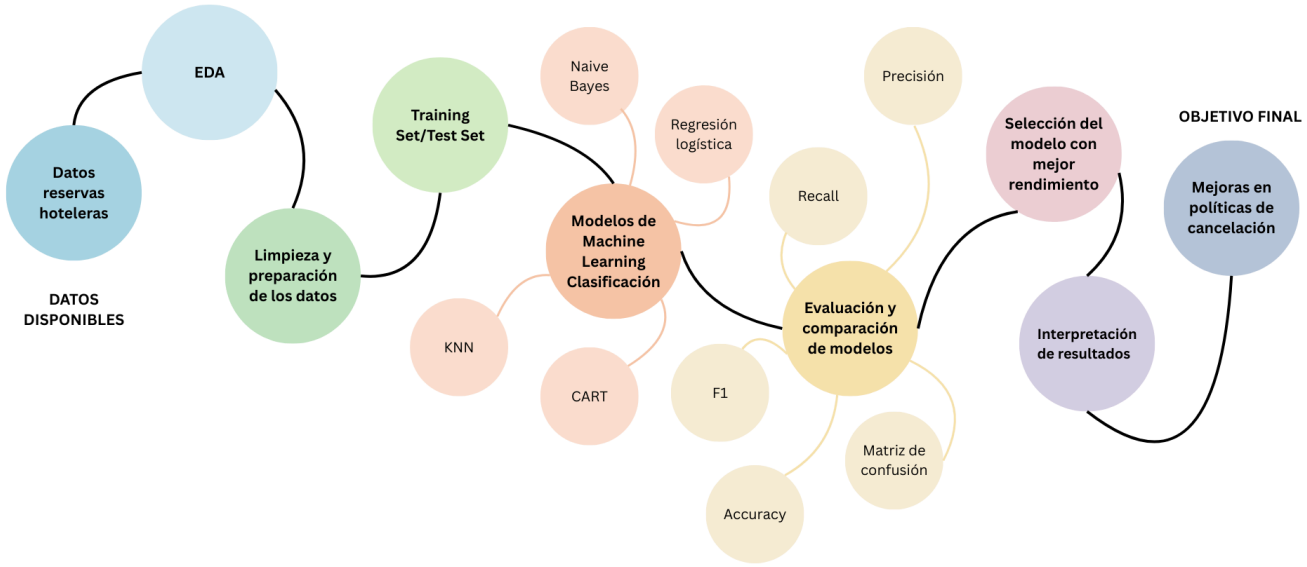
b) **Necesidades técnicas:** Se necesitarán diferentes herramientas de análisis de datos, en conjunto con librerías de Machine Learning para agilizar la creación y evaluación de modelos. También, un entorno de desarrollo adecuado.

c) **Necesidades metodológicas:** Una definición clara del objetivo del problema. Una selección de métricas de evaluación adecuadas. Llevar a cabo estrategias para evitar el overfitting. Validación exhaustiva de los modelos.

d) **Necesidades de negocio:** Generación de información relevante y capacidad para integrar el modelo seleccionado en sistemas de gestión hotelera. Interpretabilidad del modelo para facilitar su uso a las empresas del sector.

El correcto cumplimiento de estas necesidades nos permitirá garantizar la validez del análisis y de nuestro trabajo y la aplicabilidad de los resultados obtenidos.

Flujo metodológico del proyecto de Machine Learning para la predicción de cancelaciones hoteleras[1]



[1] **Figura 1**. Flujo metodológico del proyecto de Machine Learning para la predicción de cancelaciones hoteleras, se incluye lo visto hasta ahora en la asignatura, si se estudiase a posteriori alguna metodología más que pudiera ser utilizada en el trabajo, se añadiría a este.

Metodología de trabajo y técnicas previstas a utilizar

Para el desarrollo del proyecto seguiremos una metodología estructurada basada en las distintas fases del ciclo de vida de un proyecto de Machine Learning. En cada una de estas fases se aplicarán técnicas específicas orientadas a resolver el problema de predicción. Podemos ver el flujo metodológico usado en la Figura 1.

En una primera fase se realiza un análisis exploratorio de los datos con el objetivo de comprender la estructura de la base de datos e identificar patrones iniciales. Para ello, emplearemos técnicas estadísticas descriptivas y visualización de datos, tales como distribuciones de variables, análisis de correlaciones y gráficos exploratorios. Asimismo, se analizarán posibles problemas como valores perdidos, presencia de outliers y desbalance en la variable objetivo.

Una vez comprendidos los datos, se llevará a cabo un preprocesamiento. En esta fase realizaremos una limpieza de datos, el tratamiento de valores nulos y la transformación de variables necesarias en dummies. Como técnicas que utilizaremos para ello se encuentran la codificación de variables categóricas (one-hot encoding) y, en caso necesarios, la normalización o estandarización de variables numéricas para mejorar el rendimiento de ciertos algoritmos.

La siguiente fase consiste en la selección de variables. Analizaremos la relevancia de estas para poder mejorar la capacidad predictiva de los modelos y reducir la complejidad del problema tras la eliminación de variables poco relevantes. Se valorará la posible aplicación de técnicas de reducción de dimensionalidad si es que fuera necesario.

Podemos pasar entonces al entrenamiento de modelos de clasificación. Esta es la fase central del proyecto. Utilizaremos distintos modelos de Machine Learning. Se trata de una clasificación binaria y se usan algoritmos supervisados como regresión logística (modelo Logit), árboles de decisión, Random Forest y K-Nearest Neighbors (KNN). Para ello se dividirá el conjunto en subconjuntos de entrenamiento y prueba (train/test split) para poder evaluar la capacidad de generalización de los modelos.

Tras la aplicación de un modelo deberá realizarse su evaluación. Para ello utilizaremos técnicas como la validación cruzada (cross-validation) y métodos como el Grid Search o Random Search para poder realizar el ajuste de hiper parámetros como la k del KNN.

A continuación, de entre los diversos modelos evaluados tendremos que comparar distintas métricas para problemas de clasificación. Estas métricas son el accuracy, la precisión, recall y F1-Score. Esta evaluación nos permitirá la comparación entre algoritmos y de esa manera seleccionaremos el modelo más adecuado.

Finalmente, una vez tengamos el modelo y sus resultados, los analizaremos para poder interpretar el comportamiento del modelo y extraer conclusiones relevantes desde el punto de vista predictivo y empresarial. Esta fase es fundamental, ya que no solo se busca obtener un modelo con buen rendimiento sino también comprender los factores que influyen en la cancelación de reservas.

Para ello, analizaremos la importancia de las variables y cómo es su influencia en la probabilidad de cancelación. En el caso de los modelos directamente interpretables, como la regresión logística o de árboles de decisión, se estudiará directamente la relación de las variables explicativas con la dependiente. Para modelos más complejos, como Random Forest utilizaremos medidas de importancia de variables. Podremos detectar así los patrones de comportamiento relevantes.

En conjunto, la metodología propuesta permite abordar el problema de predicción de cancelaciones de forma estructurada y rigurosa, cubriendo todas las fases clave de un proyecto de Machine Learning.

Recursos a emplear

Para el desarrollo del presente proyecto se emplearán distintos recursos tanto a nivel de datos como herramientas técnicas, necesarios para llevar a cabo el análisis y la construcción de los modelos predictivos.

En primer lugar, el recurso principal será la Base de datos[2] de la plataforma kaggle referente a las reservas hoteleras. En concreto se utilizará el dataset Hotel Booking Demand, que contiene información detallada sobre reservas de hoteles, incluyendo variables relacionadas con características de los clientes, condiciones de la reserva y su estado final (cancelada o no cancelada).

En cuanto a recursos técnicos, se empleará lenguaje de programación de Python, que es el usado comúnmente en el ámbito del análisis de datos. Emplearemos librerías como pandas y NumPy, y para la visualización se utilizarán herramientas como MatplotLib. Para implementar los modelos de Machine Learning usaremos la librería scikit-learn, que proporciona una amplia variedad de algoritmos de clasificación, así como herramientas para la evaluación y validación de modelos.

El desarrollo del proyecto se llevará a cabo en el entorno de programación Visual Studio Code. A través de la extensión Live Share se permite la edición de notebooks paralelamente. VS Code permite combinar código, visualización y documentación de forma estructurada.

[2] https://www.kaggle.com/datasets/jessemostipak/hotel-booking-demand?resource=download

Resultados esperados alcanzar

El proyecto tiene como principal objetivo demostrar la aplicación de las técnicas de Machine Learning a un problema real en el ámbito empresarial, concretamente en el sector hotelero, en la gestión de reservas. Los resultados esperados del proyecto pueden analizarse desde distintos niveles: académico, tecnológico y empresarial.

1. Resultados esperados a nivel académico

El proyecto busca aplicar todos los conocimientos aprendidos en la asignatura en relación con las técnicas de clasificación supervisada. Se pretende demostrar la capacidad de:

1. Aplicar correctamente distintos algoritmos de clasificación
2. Seguir de manera ordenada, todos los pasos necesarios para la aplicación de las distintas técnicas estudiadas, como puede ser:
    a. Limpieza de datos
    b. División del conjunto de datos en training set y test set
    c. Entrenamiento de los modelos
3. Evaluar el rendimiento de todos los modelos utilizados mediante métricas apropiadas, para la correcta elección del clasificador más apropiado.

Desde esta perspectiva, el proyecto constituye una aplicación práctica de los contenidos teóricos de la asignatura, acercando las técnicas estudiadas al análisis de un problema real de negocio.

2. Resultados esperados a nivel tecnológico

Desde una perspectiva tecnológica, el proyecto tiene como objetivo consolidar las competencias adquiridas durante el desarrollo de las prácticas realizadas a lo largo de la asignatura, especialmente en relación con la programación en Python aplicada al análisis de datos y al Machine Learning. Uno de los resultados esperados en este ámbito es el desarrollo de una mayor soltura en el manejo del ecosistema de librerías de Python.

Otro objetivo relevante a nivel tecnológico es desarrollar la capacidad de integrar diferentes herramientas dentro de un mismo proyecto, combinando técnicas de análisis de datos,

modelización predictiva y visualización para comunicar los resultados de forma clara y comprensible.

En este sentido, el proyecto busca aproximarse al tipo de tareas que habitualmente realizan profesionales del ámbito de la analítica de datos y el business analytics, donde no solo es importante construir modelos predictivos, sino también presentar los resultados de forma estructurada y orientada a la toma de decisiones empresariales.

Por tanto, el desarrollo del trabajo permitirá no solo reforzar conocimientos técnicos, sino también adquirir una experiencia práctica más cercana a la que se requiere en entornos laborales relacionados con el desarrollo de soluciones basadas en Machine Learning.

3. Resultados esperados a nivel empresarial

Desde el punto de vista empresarial, el proyecto pretende demostrar cómo el uso de modelos predictivos puede contribuir a mejorar la toma de decisiones en el sector hotelero.

Una vez, se han llegado a los objetivos tanto académicos como la implementación tecnológica, se espera poder llegar a unos resultados que puedan ser interpretados desde una perspectiva empresarial y aplicados de forma práctica en el contexto del sector hotelero.

En este sentido, uno de los principales resultados esperados consiste en la capacidad de transformar los resultados obtenidos mediante los modelos predictivos en conclusiones claras. El objetivo no se limita únicamente a la construcción de modelos de Machine Learning con buen rendimiento predictivo, sino también a que los resultados obtenidos puedan ser interpretados y comunicados de manera comprensible para gestores hoteleros. El proyecto pretende demostrar cómo las técnicas de analítica de datos pueden convertirse en herramientas de apoyo a la toma de decisiones empresariales.

Por tanto, uno de los objetivos es demostrar que los modelos desarrollados no solo son útiles desde un punto de vista técnico, sino que también pueden proporcionar información relevante para mejorar la gestión de los establecimientos hoteleros.